

Modèle de régression linéaire multiple

Aba DIOP
(*aba.diop@uadb.edu.sn*)

Département de Mathématiques
Université Alioune Diop
Bambey - Sénégal

Janvier 2024

Sommaire

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

- 1 Introduction
- 2 Présentation du modèle linéaire multiple
- 3 Estimation
- 4 Adéquation du modèle
- 5 Exemple pratique

Introduction

Contexte

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

- Les modèles de régression sont construits dans le but **d'expliquer** (ou **prédire**, selon la perspective de l'analyse) la variabilité d'un phénomène Y (*variable dépendante*) à l'aide d'une combinaison de plusieurs facteurs explicatifs (*variables indépendantes*) $X_1, \dots, X_p, (p \geq 2)$
- Dans le cas de la régression linéaire multiple, la variable dépendante est toujours une **variable continue (quantitative)** tandis que les variables indépendantes peuvent être **continues** ou **catégorielles**
- La régression linéaire est appelée **multiple** lorsque le modèle est composé d'au moins deux variables indépendantes

Introduction

Contexte

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

- Le modèle de régression linéaire multiple est l'outil statistique le plus habituellement mis en œuvre pour l'étude de données multidimensionnelles.
- Exemples
 - 1 Une analyse de régression multiple peut révéler une relation positive/négative entre la **tension artérielle** (*variable à expliquer*) et différents caractères démographiques (*âge, revenu, lieu d'habitation, poids* etc.) des individus d'une ville. La TA peut augmenter ou baisser en fonction des variations de ces caractéristiques.
 - 2 Evaluer le prix du loyer en fonction de certaines caractéristiques (*superficie, nombre de chambres, placement, distante par rapport à la plage* etc.)
 - 3 Evaluer la production agricole en fonction de la *température*, la *superficie emblavée*, la *quantité d'engrais*, la *pluviométrie* etc.

Introduction

Quelques prémisses

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

1. Les **types de variables à utiliser** :

Indépendantes : continues ou catégorielles
(ordinales ou dichotomiques)

Dépendante : continue

2. **Pas de variance égale à zéro** : la distribution des prédicteurs doit comprendre une certaine variance, donc ne doit pas être constante

3. **Aucune multicolinéarité parfaite** : il ne doit pas y avoir de relation linéaire parfaite entre deux ou plusieurs variables indépendantes. Par conséquent, les corrélations ne doivent pas être trop fortes entre celles-ci

Cette dernière prémisse peut être vérifiée avec le
VIF (*Variance Inflation Factor*) indiquant si une
variable indépendante a une relation linéaire
forte avec les autres

Introduction

Quelques prémisses

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

4. **Indépendance de la variable prédite** : toutes les observations formant la distribution des valeurs de la variable dépendante sont indépendantes, donc viennent d'individus différents
5. **Relation linéaire** entre les **variables indépendantes** et la **variable dépendante** : la variation de la variable dépendante pour chaque augmentation d'une unité d'une variable indépendante suit une ligne droite
6. Les variables d'influence doivent toutes être incluses dans le modèle
7. Prémisses liées aux erreurs (*centrées, homoscedasticité, indépendance, distribution normale*)

Introduction

Prémises sur les erreurs

- **Centrées** : les moyennes des erreurs sont nulles
- **Homoscédasticité** (*homogénéité des variances des erreurs*) : la variance des valeurs résiduelles doit être similaire à tous les niveaux de la variable indépendante
- **Indépendance des erreurs** : les valeurs résiduelles ne doivent pas être corrélées entre les individus. Cette prémisses peut être vérifiée avec la statistique Durbin-Watson qui se situe entre 0 et 4, une valeur de 2 indiquant une absence de corrélation, moins de 2 une corrélation positive et plus de 2, une corrélation négative. La règle arbitraire est que la valeur ne doit pas être plus petite que 1 ou plus grande que 3
- **Distribution normale des erreurs** : les résidus doivent suivre une distribution normale (test de Kolmogorov-Smirnov, de Shapiro-Wilks ou de Jarque-Bera)

Introduction

Conception d'un modèle de régression

- La conception d'un modèle de régression devrait faire l'objet d'une réflexion préalable portant sur
 - 1) le choix des variables indépendantes
 - 2) le choix de la méthode de régression : méthodes ***ascendante*** (forward), ***descendante*** (backward), ***pas-à-pas*** (stepwise)
- Le choix des variables indépendantes doit être guidé par le principe de **parcimonie** qui veut qu'un bon modèle comprend un **nombre optimal** de variables et par la présence d'un lien théorique connu ou présumé avec la variable dépendante
- La puissance statistique du devis : le nombre d'observations détermine la quantité maximale de variables qu'un modèle peut supporter. Plus on a d'observations, plus on peut inclure de variables dans le modèle.

Introduction

Méthode ascendante (forward)

- Le modèle initial ne contient que la constante (β_0). Celui-ci servira de base de comparaison pour déterminer si l'ajout d'une variable contribue significativement à l'amélioration du modèle
- Ensuite, on choisit parmi les variables indépendantes soumises celle qui a la plus forte corrélation avec la variable dépendante. On évalue si cet ajout est significatif. Si c'est le cas, on l'intègre
- On parle de corrélation partielle puisque le calcul est effectué avec la variance de la variable dépendante qui reste à expliquer une fois que l'effet de la première variable est retiré
- On répète les deux phases précédentes. On arrête l'inclusion de nouvelles variables lorsque l'augmentation de la valeur du R^2 n'est plus significative

Introduction

Méthode pas-à-pas (stepwise)

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

- Cette méthode ressemble beaucoup à la méthode ascendante, puisque le choix de la première variable est encore basé sur la corrélation la plus élevée avec la variable dépendante
- Le choix des variables suivantes est basé sur la corrélation partielle
- Toutefois, lorsque l'on ajoute une variable au modèle, on doit évaluer si elle apporte une contribution significative, mais également si celle qui contribuait le moins au modèle demeure significative. Si ce n'est pas le cas, on la retire. De cette manière, il est possible d'éliminer les variables redondantes

Introduction

Méthode descendante (backward)

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

- Le modèle initial comprend toutes les variables, comme pour la régression forcée
- On va retirer la variable ayant la plus faible contribution au modèle si la variation du coefficient de détermination R^2 n'est pas significative en l'éliminant
- La procédure va être répétée jusqu'à ce que toutes les variables conservées contribuent significativement à l'amélioration du R^2
- On peut également utiliser la p_{value} pour évaluer l'impact significatif d'un prédicteur

Présentation du modèle linéaire multiple

Définition du modèle de régression multiple

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

Modèle

Étant donné un échantillon $(Y_i, X_{i1}, \dots, X_{ip})_{1 \leq i \leq n}$, on cherche à expliquer, avec le plus de précision possible, les valeurs prises par Y_i (variable dépendante) à partir d'une série de variables explicatives $X_{i1}, \dots, X_{ip}$ sous la forme suivante :

$$\mathbf{Y}_i = \beta_0 + \beta_1 \mathbf{X}_{i1} + \beta_2 \mathbf{X}_{i2} + \dots + \beta_p \mathbf{X}_{ip} + \epsilon_i, \quad i = 1, \dots, n$$

Commentaires

- $\beta_0, \beta_1, \dots, \beta_p$: paramètres de régression (à estimer)
- La constante β_0 correspond à la valeur de la variable dépendante lorsque toutes les variables indépendantes égalent 0 (donc non significatives)

Présentation du modèle linéaire multiple

Présentation du modèle de régression multiple

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

Commentaires

- X_{ij} est observée et non aléatoire
- Y_{ij} est observée et aléatoire
- Chaque variable indépendante X_j est multipliée par son propre coefficient β_j qui correspond à sa contribution relative dans le modèle ($j = 1, \dots, p$)
- $\epsilon_1, \dots, \epsilon_n$ représentent les erreurs du modèle et sont supposés aléatoires. Ils expriment, ou résument, l'information manquante dans l'explication linéaire des valeurs de Y_i à partir des valeurs de $X_{i1}, \dots, X_{ip}$ (problème de spécifications, variables non prises en compte, etc.)

Présentation du modèle linéaire multiple

Objectifs du modèle de régression multiple

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

- 1 Estimer les paramètres $\beta_0, \beta_1, \dots, \beta_p$ en utilisant les observations
- 2 Evaluer la précision de ces estimateurs (consistance, efficacité)
- 3 Mesurer le pouvoir explicatif (prédicatif) du modèle
- 4 Evaluer l'influence individuelle et globale des variables explicatives dans le modèle
- 5 Evaluer l'adéquation du modèle par rapport aux données
- 6 Evaluer la qualité du modèle lors de la prédiction (intervalle de prédiction)
- 7 Détecter et évaluer les observations qui peuvent influencer exagérément les résultats (points atypiques)

Présentation du modèle linéaire multiple

Ecriture matricielle

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

Ecriture matricielle du modèle

$$\begin{cases} Y_1 = \beta_0 + \beta_1 X_{11} + \beta_2 X_{21} + \dots + \beta_p X_{1p} + \epsilon_1 \\ Y_2 = \beta_0 + \beta_1 X_{21} + \beta_2 X_{22} + \dots + \beta_p X_{2p} + \epsilon_2 \\ \vdots \\ Y_n = \beta_0 + \beta_1 X_{n1} + \beta_2 X_{n2} + \dots + \beta_p X_{np} + \epsilon_n \end{cases}$$

Ecriture matricielle du modèle

$$\begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix} = \begin{pmatrix} 1 & X_{11} & \dots & X_{1p} \\ 1 & X_{21} & \dots & X_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & X_{n1} & \dots & X_{np} \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix} + \begin{pmatrix} \epsilon_1 \\ \vdots \\ \epsilon_n \end{pmatrix}$$

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$$

Présentation du modèle linéaire multiple

Hypothèses du modèle de régression multiple

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

Hypothèses stochastiques

C₁ : $\mathbb{E}(\epsilon_i) = 0, i = 1, \dots, n$ (**variables centrées**)

C₂ : $\text{Var}(\epsilon_i) = \sigma^2$ (**inconnue**), $i = 1, \dots, n$ (**homoscédasticité**)

C₃ : $\text{Cov}(\epsilon_i, \epsilon_j) = 0, 1 \leq i \neq j \leq n$, (**non autocorrélation**)

C₄ : $\text{Cov}(X_{ij}, \epsilon_{ik}) = 0, \forall j \neq k$ (**les erreurs sont linéairement indépendantes des variables exogènes**)

C₅ : $\epsilon_i \rightsquigarrow \mathcal{N}(0, \sigma^2), i = 1, \dots, n$, (**erreurs gaussiennes**)

Hypothèses structurelles

C₆ : Les prédicteurs $X_1, \dots, X_n$ sont linéairement indépendants ($\text{Rg}(\mathbf{X}) = \text{Rg}(\mathbf{X}'\mathbf{X}) = p + 1$)

C₇ : $\frac{1}{n}\mathbf{X}'\mathbf{X}$ tend vers une matrice finie non singulière Q lorsque $n \rightarrow +\infty$

C₈ : $n > p + 1$

Estimation

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

- Pour estimer le vecteur des paramètres $\beta = (\beta_0, \beta_1, \dots, \beta_p)$, on peut utiliser la méthode des **moindres carrés ordinaires** qui ne nécessite pas d'hypothèse supplémentaire sur la distribution des erreurs ϵ_i , contrairement à la **méthode du maximum de vraisemblance** qui est fondée sur la **normalité** des ϵ_i
- La méthode des moindres carrés ne fournit pas un estimateur de la variance des erreurs σ^2

Estimation par Moindres Carrés Ordinaires

On cherche l'estimateur $\hat{\beta}$ de β qui minimise la somme des **erreurs quadratiques**

$$S(\beta) = \sum_{i=1}^n \epsilon_i^2 = \sum_{i=1}^n [Y_i - \beta_0 - \beta_1 X_{i1} - \dots - \beta_p X_{ip}]^2$$

Estimation par Moindres Carrés Ordinaires

- L'estimateur par MCO $\hat{\beta}$ de β a pour expression

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$$

- Propriétés de l'EMCO $\hat{\beta}$

$$\mathbb{E}(\hat{\beta}) = \beta \quad (\text{sans biais})$$

$$\mathbb{V}(\hat{\beta}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$$

$$\frac{\hat{\beta}_j - \beta_j}{\hat{\sigma}_{\hat{\beta}_j}} \rightsquigarrow t_{n-p-1}$$

- **Propriété de Gauss-Markov : BLUE** (*Best Linear Unbiased Estimator*) : meilleur estimateur parmi les estimateurs linéaires et sans biais de β

Estimation

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

Définitions

- **Valeurs prédites :**

$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_{i1} + \dots + \hat{\beta}_p X_{ip}, i = 1, \dots, n.$ Ces valeurs estiment les espérances $\mathbb{E}(Y_i) = \beta_0 + \beta_1 X_{i1} + \dots + \beta_p X_{ip}$

- **Résidus :** $\hat{\epsilon}_i = Y_i - \hat{Y}_i, i = 1, \dots, n.$ On a $\sum_{i=1}^n \hat{\epsilon}_i = 0$

Variance résiduelle

- La variance des erreurs σ^2 est estimée par

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n \hat{\epsilon}_i^2}{n - p - 1} \quad (\text{estimateur sans biais})$$

- La perte de $p + 1$ degrés de liberté dans l'expression de $\hat{\sigma}^2$ est le **coût** de l'estimation de $\beta_0, \beta_1, \dots, \beta_p$ nécessaire pour obtenir les valeurs ajustées $\hat{Y}_i$

Adéquation du modèle : Test de Fisher

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

Décomposition de la variance

- Tableau d'analyse de la variance

Source de variation	Somme des carrés	d.d.l.	Carrés mo
Expliquée (SCE)	$\sum_{i=1}^n (\hat{y}_i - \bar{y})^2$	1	$\frac{SCE}{p}$
Résiduelle (SCR)	$\sum_{i=1}^n (y_i - \hat{y}_i)^2$	$n - 2$	$\frac{SCR}{n-p-1}$
Totale (SCT)	$\sum_{i=1}^n (y_i - \bar{y})^2$	$n - 1$	F

- SCE (**Somme des Carrés Expliquée**) : variation expliquée par le modèle
- SCR (**Somme des Carrés Résiduelle**) : variation non expliquée par le modèle
- SCT (**Somme des Carrés Totale**) : variation totale
- Equation d'analyse de la variance : **$SCT = SCE + SCR$**

Adéquation du modèle : Test de Fisher

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

Significativité globale

- Test de Fisher

$$\begin{cases} H_0 : \text{Le modèle n'est pas significatif} \\ H_1 : \text{Le modèle est significatif} \end{cases}$$

- Statistique du test

$$F = \frac{n-2}{p} \frac{SCE}{SCR} \longrightarrow \mathcal{F}_{1,n-2}, \text{ sous } H_0$$

$$p_{value} = \mathbb{P}(\mathcal{F}_{1,n-2} > F/H_0)$$

- **Décision** : on rejette H_0 (*le modèle est significatif*) au seuil $\alpha \in [0; 1]$ si $p_{value} < \alpha$ ou si F est supérieur au quantile d'ordre $1 - \alpha$ de la loi de Fisher $\mathcal{F}_{1,n-2}$

Pouvoir explicatif du modèle

Modèle de régression linéaire multiple

A. DIOP

Introduction

Présentation du modèle linéaire multiple

Estimation

Adéquation du modèle

Exemple pratique

Coefficient de détermination (ou d'ajustement)

- **Coefficient de détermination (ou d'ajustement)** : Il mesure l'adéquation entre le modèle et les données observées (il permet de mesurer la part de variation expliquée par le modèle : *pouvoir explicatif ou prédictif du modèle*)

$$R^2 = \frac{SCE}{SCT} = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}, \quad 0 < R^2 < 1$$

- Si le modèle est bien adapté aux données alors R^2 sera proche de 1 ($R^2 \geq 0.75$)
- Si le modèle est mal adapté aux données alors R^2 sera proche de 0 $\Rightarrow$ étudier l'impact des valeurs influentes, problèmes de données manquantes ou réponses erronées etc.

Etude des résidus

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

Contrôle des résidus

Tout ce qui a été fait jusqu'ici suppose que

- $(\mathbf{C}_1) : \mathbb{E}(\epsilon_i) = 0, \forall i$ (*les erreurs sont centrées*)
- $(\mathbf{C}_2) : \mathbb{V}(\epsilon_i) = \sigma^2, \forall i$ (*constante*), *homogénéité des variances ou homoscélasticité*
- $(\mathbf{C}_3) : \text{Cov}(\epsilon_i, \epsilon_j) = 0, \forall i \neq j$ *non autocorrélation des résidus*
- $(\mathbf{C}_4) : \epsilon_i \sim \mathcal{N}(0, \sigma^2), \forall i$ *les erreurs sont gaussiennes*

On désire vérifier à l'issue de l'estimation si ces hypothèses sont satisfaites par les résidus $(\hat{\epsilon}_i)_{1 \leq i \leq n}$ du modèle

Etude des résidus

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

Contrôle des résidus : Approche graphique

- La présence d'une relation de degré supérieur (quadratique, cubique, etc.), ou d'une form exponentielle, logarithmique, ou d'interactions peut causer une mauvaise caractérisation de la relation (*problème de linéarité*) et des biais dans l'estimation
- On trace le nuage de points correspondants aux couples $(\hat{y}_i, \hat{\epsilon}_i)_{1 \leq i}$ ou aux couples $(x_i, \hat{\epsilon}_i)_{1 \leq i}$
- Si les résidus du modèle sont centrés, alors le nuage de points sera distribué de façon uniforme et de part et d'autre de la droite de régression locale (en rouge)

Etude des résidus

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

Contrôle des résidus : Approche graphique

- L'homogénéité des variances est vérifiée si le nuage de points ne présente pas de forme en trompette ou d'entonnoir (concentrés au départ et élargis au fur et à mesure ou élargis au départ et se concentre au fur et à mesure)
- L'homogénéité des variances n'est pas vérifiée si tous les résidus sont positifs ou négatifs
- La non autocorrélation des résidus est vérifiée si des résidus négatifs sont suivis par des résidus positifs.

Etude des résidus

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

Contrôle des résidus : Approche graphique

- On note la présence d'autocorrélation des résidus si des résidus négatifs succèdent à plusieurs autres résidus négatifs et vice versa. L'autocorrélation peut provenir de :
 - * *Dépendance spatiale ou temporelle entre les observations (évitable en préparant adéquatement la collecte)*
 - * $\Rightarrow$ *Mauvaise estimation de la variance, largeur de l'intervalle de confiance, significativité erronée*
 - * **Solution** : *Ajouter une variable explicative pour expliquer la dépendance, Modèle mixte, Modèle pour séries chronologiques*
- Si le nuage de points s'allonge autour de la première bissectrice (Quantile-Quantile-Plots ou droite de Henry), alors l'hypothèse de normalité des résidus est vérifiée

Contrôle des résidus : Tests d'hypothèses

- Test de Student : Nullité e la moyenne des rsidus

$$\begin{cases} H_0 : \mathbb{E}(\epsilon_i) = 0 & \text{Les résidus sont centrés} \\ H_1 : \mathbb{E}(\epsilon_i) \neq 0 & \text{Les résidus sont non centrés} \end{cases}$$

On accepte H_0 au seuil de risque $\alpha \in [0; 1]$ si $p_{value} > \alpha$

- Test de Harisson Mcabe (Test de Levenne)

$$\begin{cases} H_0 : \mathbb{V}(\epsilon_1) = \dots = \mathbb{V}(\epsilon_1) = \sigma^2 & \text{(Homoscédasticité)} \\ H_1 : \exists i \neq j \text{ tel que } \mathbb{V}(\epsilon_i) \neq \mathbb{V}(\epsilon_j) & \text{(Hétéroscédasticité)} \end{cases}$$

On accepte H_0 au seuil de risque $\alpha \in [0; 1]$ si $p_{value} > \alpha$

Etude des résidus

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

Contrôle des résidus : Tests d'hypothèses

- Test de Durbin-Watson : autocorrélation des résidus

$$\begin{cases} H_0 : \text{Cov}(\epsilon_i, \epsilon_j) = 0, & i \neq j & \text{Non autocorrélation} \\ H_1 : \text{Cov}(\epsilon_i, \epsilon_j) \neq 0, & i \neq j & \text{Autocorrélation} \end{cases}$$

On accepte H_0 au seuil de risque $\alpha \in [0; 1]$ si $p_{\text{value}} > \alpha$

- Test de normalité : Shapiro-Wilk, Jarque-Bera, Kolmogorov-Smirnov

$$\begin{cases} H_0 : (\epsilon_1, \dots, \epsilon_n) & \text{est gaussien} \\ H_1 : (\epsilon_1, \dots, \epsilon_n) & \text{est non gaussien} \end{cases}$$

On accepte H_0 au seuil de risque $\alpha \in [0; 1]$ si $p_{\text{value}} > \alpha$

Etude des valeurs atypiques

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

Sources de biais : Valeurs atypiques

- **Valeur aberrante** : Observation ayant une combinaison de valeurs (y, x) très différente du reste des observations $\Rightarrow$ impact léger
- **Levier** : Observation ayant une valeur de y éloignée de la moyenne de $x \Rightarrow$ impact léger
- **Valeur influente** : Observation avec levier et valeur de y différente des autres avec mêmes valeurs de $x \Rightarrow$ impact sur paramètres estimés et prédiction
- Effectuer une analyse de sensibilité : comparer le modèle avec les observations atypiques et le modèle sans ces observations

Conditions du modèle

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

Non respect des conditions

- En fait, même si les conditions du modèle linéaire ne sont pas respectées, il se pourrait que tout aille bien tout de même (**ouf!**) : **Robustesse du modèle linéaire** (c'est-à-dire que sous réserve qu'il y ait une taille d'échantillon suffisante, les résultats du modèle linéaire restent valables $\Rightarrow$ propriétés asymptotiques)
- Plus on a de données à disposition, plus le modèle est capable de supporter un écart important aux conditions
- L'application du modèle linéaire n'exige pas un respect exact des hypothèses, mais un respect approximatif

Cas pratique

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

Données

- **LOC** : prix du loyer
- **SURF** : superficie totale
- **CHAMB** : nombre de chambres
- **SCHAMB** : superficie des chambres
- **SDB** : superficie des salles de bain
- **SSDB** : nombre de salles de bain
- **PARK** : nombre de parkings
- **PLAGE** : distance par rapport à la plage
- **UNIV** : distance par rapport à la plage

Cas pratique : Etude la linéarité entre variables

Modèle de régression linéaire multiple

A. DIOP


Introduction

Présentation du modèle linéaire multiple

Estimation

Adéquation du modèle

Exemple pratique



Cas pratique : Etude la linéarité entre variables

Modèle de
régression
linéaire
multiple

A. DIOP


Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique



Ajustement du modèle : Sélection de variable

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	259.0977	43.8148	5.91	0.0000
SURF	8.1078	1.4901	5.44	0.0000
CHAMB	-9.6802	19.0886	-0.51	0.6186
SCHAMB	12.5586	2.4213	5.19	0.0001
SDB	19.9240	27.5161	0.72	0.4789
SSDB	4.0917	6.0194	0.68	0.5058
PARK	32.3263	6.9564	4.65	0.0002
PLAGE	-12.2185	1.7794	-6.87	0.0000
UNIV	-3.1300	1.3643	-2.29	0.0348

Ajustement du modèle : Sélection de variable

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	247.5377	36.6378	6.76	0.0000
SURF	8.2733	1.4236	5.81	0.0000
SCHAMB	11.3937	0.7493	15.21	0.0000
SDB	26.0751	24.1834	1.08	0.2952
SSDB	5.4879	5.2413	1.05	0.3089
PARK	31.2007	6.4553	4.83	0.0001
PLAGE	-12.8182	1.3018	-9.85	0.0000
UNIV	-3.4306	1.2032	-2.85	0.0106

Ajustement du modèle : Sélection de variable

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	252.7004	36.3963	6.94	0.0000
SURF	7.8165	1.3586	5.75	0.0000
SCHAMB	11.5947	0.7262	15.97	0.0000
SDB	45.7677	15.2404	3.00	0.0073
PARK	31.7814	6.4477	4.93	0.0001
PLAGE	-12.3681	1.2319	-10.04	0.0000
UNIV	-3.1062	1.1655	-2.67	0.0153

Cas pratique : Etude des observations atypiques

Modèle de
régression
linéaire
multiple

A. DIOP


Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique



Cas pratique : Etude des observations atypiques

Modèle de
régression
linéaire
multiple

A. DIOP


Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique



Cas pratique : Etude des observations atypiques

Modèle de
régression
linéaire
multiple

A. DIOP


Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique



Cas pratique : Etude des observations atypiques

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple


Estimation

Adéquation du
modèle


Exemple
pratique

page 1 of 2


Influence Diagnostics for (Intercept)




Influence Diagnostics for SCHAMB



Influence Diagnostics for SURF



Influence Diagnostics for SDB



Cas pratique : Etude des observations atypiques

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple


Estimation

Adéquation du
modèle


Exemple
pratique

page 2 of 2


Influence Diagnostics for PARK



Influence Diagnostics for UNIV



Influence Diagnostics for PLAG



Etude des observations influentes

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

Comparaison des modèles

	AIC	BIC	R^2	R^2 ajusté
Modèle initial	224.7953	234.8601	0.9953	0.9938
Modèle modifié	211.73	221.4811	0.9963	0.995

Commentaire : Le **modèle modifié** a été estimé dans l'échantillon privé de l'individu **11**. On constate que son AIC est inférieur à celui du premier modèle et son coefficient de détermination augmente.

Diagnostic du modèle

Modèle de
régression
linéaire
multiple

A. DIOP





Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique



Diagnostic du modèle

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple


Estimation

Adéquation du
modèle

Exemple
pratique


Posterior Predictive Check

Model-predicted lines should resemble observed data




Linearity

Reference line should be flat and horizontal




Homogeneity of Variance

Reference line should be flat and horizontal




Influential Observations

Points should be inside the contour lines




Collinearity

Higher bars (>5) indicate potential collinearity issues



Normality of Residuals

Points should fall along the line



Etude de la multicollinéarité

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

Facteur d'inflation de la variance (VIF)

Variables	SURF	SCHAMB	SDB	PARK	PLAGE	UNIV
VIF	7.5758	6.7312	6.2411	1.7983	1.4497	1.8164

- La racine carrée du VIF indique de combien de fois l'erreur standard d'une pente partielle est augmentée à cause de la multicollinéarité
- Une valeur de **VIF inférieure à 5** indique une faible corrélation de cette variable explicative avec les autres variables explicatives
- Une valeur de **VIF comprise entre 5 et 10** indique une corrélation modérée
- Les valeurs **VIF supérieures à 10** sont le signe d'une corrélation élevée et non tolérable

Présentation des résultats

Modèle de
régression
linéaire
multiple

A. DIOP

Introduction

Présentation
du modèle
linéaire
multiple

Estimation

Adéquation du
modèle

Exemple
pratique

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	231.4886	34.5131	6.71	0.0000
SURF	8.2681	1.2543	6.59	0.0000
SCHAMB	11.0586	0.7045	15.70	0.0000
SDB	55.0805	14.5071	3.80	0.0013
PARK	28.9212	6.0141	4.81	0.0001
PLAGE	-12.1993	1.1248	-10.85	0.0000
UNIV	-2.6672	1.0801	-2.47	0.0238

$R^2 = 99.53\% \Rightarrow$ le modèle a un très bon pouvoir explicatif