

DATASET 1 : SANTÉ

https://drive.google.com/file/d/1OG5a1pP_AhwEtpyTnNVc2PlxUc5FJhtV/view?usp=sharing

Description

Cet ensemble de données contient des informations cliniques et administratives relatives aux patients hospitalisés, incluant leurs diagnostics, traitements, paramètres vitaux et résultats médicaux.

Caractéristiques de l'ensemble de données

Multivarié

Domaine d'études

Santé / Data Science

Tâches associées

Classification, Régression, Détection d'anomalies

Type de fonctionnalité

Catégorique, Entier, Continu

Instances

3000

Caractéristiques

20

Tableau des variables

Nom de la variable	Rôle	Type	Démographique	Description	Unités	Valeurs manquantes
patient_id	ID	Entier		Identifiant patient		Non
age	Feature	Entier	Âge	Âge du patient	ans	Oui
gender	Feature	Catégorique	Genre	Sexe du patient		Oui
admission_date	Feature	Date		Date admission		Non
discharge_date	Feature	Date		Date sortie		Oui
diagnosis	Feature	Catégorique		Maladie diagnostiquée		Non
treatment	Feature	Catégorique		Traitement administré		Non
doctor_id	Feature	Entier		Identifiant médecin		Non
hospital	Feature	Catégorique		Nom hôpital		Non
cost	Feature	Continu		Coût traitement	€	Oui
insurance	Feature	Catégorique		Assurance		Oui
outcome	Target	Catégorique		Résultat		Non
blood_pressure	Feature	Entier		Tension artérielle	mmHg	Oui
heart_rate	Feature	Entier		Fréquence cardiaque	bpm	Oui
bmi	Feature	Continu		Indice masse corporelle		Oui
medication	Feature	Catégorique		Médicament		Non
dosage	Feature	Mixte		Dosage	mg	Oui
follow_up_date	Feature	Date		Suivi		Oui
readmission_flag	Target	Mixte		Réadmission		Oui

region	Feature	Catégorique		Région		Non
--------	---------	-------------	--	--------	--	-----

DATASET 2 : FINANCE (TRANSACTIONS)

https://drive.google.com/file/d/1Lkh65_39f0ucRZsRErUXw11Jm2JWcLoP/view?usp=sharing

Description

Cet ensemble de données contient des informations relatives aux transactions bancaires, incluant les montants, soldes, informations clients et indicateurs de fraude.

Caractéristiques de l'ensemble de données

Multivarié

Domaine d'études

Finance / Data Science

Tâches associées

Classification, Détection de fraude, Anomalies

Type de fonctionnalité

Catégorique, Numérique, Temporel

Instances

4000

Caractéristiques

20

Tableau des variables

Nom	Rôle	Type	Description	Valeurs manquantes
-----	------	------	-------------	--------------------

transaction_id	ID	Entier	ID transaction	Non
account_id	Feature	Entier	ID compte	Non
transaction_date	Feature	Date	Date transaction	Non
amount	Feature	Continu	Montant	Oui
balance	Feature	Mixte	Solde	Oui
transaction_type	Feature	Catégorique	Type transaction	Non
currency	Feature	Catégorique	Devise	Non
country	Feature	Catégorique	Pays	Non
merchant	Feature	Catégorique	Marchand	Non
device	Feature	Catégorique	Type appareil	Non
fraud_flag	Target	Mixte	Fraude	Oui
ip_address	Feature	Catégorique	IP	Non
login_time	Feature	Date	Connexion	Oui
logout_time	Feature	Date	Déconnexion	Oui
risk_score	Feature	Mixte	Score risque	Oui
age_client	Feature	Entier	Âge client	Oui
income	Feature	Mixte	Revenu	Oui
credit_score	Feature	Entier	Score crédit	Oui
loan_status	Feature	Catégorique	Statut prêt	Non
region	Feature	Catégorique	Région	Non

DATASET 3 : LOGISTIQUE

<https://drive.google.com/file/d/1djhSrHRr5S06vvEoKXGobLwBHxdBQqi-/view?usp=sharing>

Description

Cet ensemble de données contient des informations sur les opérations de transport et de livraison dans une chaîne logistique.

Caractéristiques

Multivarié

Domaine

Supply Chain / Data Science

Tâches

Optimisation, Anomalies

Type

Numérique, Catégorique

Instances

3500

Caractéristiques

20

Tableau variables

Variable	Type	Description
shipment_id	ID	ID livraison

origin	Catégorique	Origine
destination	Catégorique	Destination
distance	Numérique	Distance
weight	Numérique	Poids
cost	Numérique	Coût
delivery_time	Numérique	Temps réel
expected_time	Numérique	Temps prévu
delay	Numérique	Retard
vehicle_type	Catégorique	Véhicule
driver_id	Entier	Chauffeur
fuel_cost	Numérique	Carburant
weather	Catégorique	Météo
status	Catégorique	Statut
warehouse	Catégorique	Entrepôt
loading_time	Numérique	Chargement
unloading_time	Numérique	Déchargement
damage_flag	Mixte	Endommagé
priority	Catégorique	Priorité
region	Catégorique	Région

DATASET 4 : ÉDUCATION

<https://drive.google.com/file/d/1oQyHxNMTP7pa4MxiAh24htdCRty0SQgU/view?usp=sharing>

Description

Cet ensemble de données contient des informations sur les performances académiques des étudiants.

Caractéristiques

Multivarié

Domaine

Éducation / Data Science

Tâches

Classification, Régression

Instances

3000

Caractéristiques

20

Variables

Variable	Type	Description
student_id	ID	ID étudiant
age	Entier	Âge
gender	Catégorique	Sexe
grade	Catégorique	Classe

attendance	Numérique	Présence
score_math	Numérique	Score
score_stats	Numérique	Score
score_programmin g	Numérique	Score
hours_study	Numérique	Heures
internet_access	Catégorique	Accès
parent_education	Catégorique	Niveau parents
scholarship	Catégorique	Bourse
dropout_flag	Mixte	Abandon
exam_date	Date	Date exam
submission_date	Date	Soumission
cheating_flag	Mixte	Triche
gpa	Numérique	Moyenne
region	Catégorique	Région
school	Catégorique	École

DATASET 5 : INDUSTRIE

<https://drive.google.com/file/d/1k7ELO2fw2PXJLYfl3QwHcyT7TlgNuwUw/view?usp=sharing>

Description

Cet ensemble de données contient des informations issues de capteurs industriels pour le suivi de la production et de la maintenance.

Caractéristiques

Multivarié

Domaine

Industrie / IoT

Tâches

Maintenance prédictive, anomalies

Instances

4000

Caractéristiques

20

Variables

Variable	Type	Description
machine_id	ID	Machine
temperature	Numérique	Température

pressure	Numérique	Pression
vibration	Numérique	Vibration
production_count	Numérique	Production
defect_rate	Numérique	Défauts
downtime	Numérique	Arrêt
maintenance_date	Date	Maintenance
operator_id	Entier	Opérateur
shift	Catégorique	Équipe
energy_consumption	Numérique	Énergie
cost	Numérique	Coût
failure_flag	Mixte	Panne
repair_time	Numérique	Réparation
sensor_1 à sensor_5	Numérique	Capteurs
plant	Catégorique	Usine
region	Catégorique	Région

DATASET 6 : VENTES

<https://drive.google.com/file/d/12ybdsQ-u7wMvvB6ISvUwW5LKQeIVQVm/view?usp=sharing>

Description

Cet ensemble de données contient des informations relatives aux transactions de vente issues d'un système e-commerce et ERP, incluant les produits, clients, paiements, coûts et indicateurs de performance.

Les données contiennent volontairement des erreurs, incohérences et anomalies afin de simuler un environnement réel de données non nettoyées.

Caractéristiques de l'ensemble de données

Multivarié

Domaine d'études

Business Analytics / Data Science

Tâches associées

Analyse exploratoire, Nettoyage des données, Détection d'anomalies, Régression

Type de fonctionnalité

Catégorique, Entier, Continu, Temporel

Instances

10000

Caractéristiques

24

Tableau des variables

Nom de la variable	Rôle	Type	Démographique	Description	Unités	Valeurs manquantes
--------------------	------	------	---------------	-------------	--------	--------------------

order_id	ID	Entier		Identifiant commande		Non
customer_id	Feature	Catégorique	Client	Identifiant client		Oui
order_date	Feature	Date		Date commande		Non
ship_date	Feature	Date		Date expédition		Oui
delivery_date	Feature	Date		Date livraison		Oui
product	Feature	Catégorique		Produit vendu		Non
category	Feature	Catégorique		Catégorie produit		Non
subcategory	Feature	Catégorique		Sous-catégorie		Non
price	Feature	Mixte		Prix unitaire	€	Oui
quantity	Feature	Entier		Quantité		Oui
total_amount	Feature	Mixte		Montant total	€	Oui
discount	Feature	Mixte		Remise (%)	%	Oui
tax	Feature	Mixte		Taxe	%	Oui
shipping_cost	Feature	Mixte		Coût livraison	€	Oui
payment_method	Feature	Catégorique		Mode paiement		Non
sales_channel	Feature	Catégorique		Canal vente		Non
country	Feature	Catégorique		Pays		Non
city	Feature	Catégorique		Ville		Non
region	Feature	Catégorique		Région		Non
cost	Feature	Mixte		Coût produit	€	Oui
profit	Feature	Mixte		Profit	€	Oui

margin	Feature	Mixte		Marge	%	Oui
customer_rating	Feature	Mixte		Note client	/5	Oui
returned_flag	Target	Mixte		Produit retourné		Oui

DATASET 7: SPORT

<https://drive.google.com/file/d/1WJP2ilc2rQCQMpHC31dn688uX3t3u1T7/view?usp=sharing>

Description

Cet ensemble de données contient des informations relatives aux performances des joueurs et des équipes sportives, incluant les statistiques de match, les conditions physiques et les résultats.

Caractéristiques de l'ensemble de données

Multivarié

Domaine d'études

Sport Analytics / Data Science

Tâches associées

Classification, Régression, Détection d'anomalies

Type de fonctionnalité

Catégorique, Entier, Continu

Instances

3500

Caractéristiques

20

Tableau des variables

Variable	Type	Description
----------	------	-------------

player_id	ID	Joueur
age	Entier	Âge
team	Catégorique	Équipe
match_date	Date	Match
goals	Entier	Buts
assists	Entier	Passes
minutes_played	Entier	Temps jeu
distance	Numérique	Distance parcourue
speed	Numérique	Vitesse
injuries	Mixte	Blessure
training_hours	Numérique	Entraînement
fatigue_level	Numérique	Fatigue
rating	Numérique	Note
coach	Catégorique	Coach
league	Catégorique	Ligue
salary	Mixte	Salaire
win_flag	Mixte	Victoire
region	Catégorique	Région

DATASET 8 : AGRICULTURE

<https://drive.google.com/file/d/174OMmFmL1zMzULkcT9UmP3H73Aek2-O-/view?usp=sharing>

Description

Cet ensemble de données contient des informations relatives à la production agricole, incluant les rendements, les conditions climatiques et les pratiques agricoles.

Caractéristiques

Multivarié

Domaine

Agriculture / Data Science

Tâches

Régression, Prédiction, Anomalies

Instances

4000

Caractéristiques

20

Variable	Type	Description
farm_id	ID	Exploitation
crop	Catégorique	Culture

area	Numérique	Surface
yield	Numérique	Rendement
rainfall	Numérique	Pluie
temperature	Numérique	Température
fertilizer	Numérique	Engrais
pesticide	Numérique	Pesticide
soil_type	Catégorique	Sol
irrigation	Mixte	Irrigation
cost	Numérique	Coût
revenue	Numérique	Revenu
profit	Numérique	Profit
season	Catégorique	Saison
region	Catégorique	Région

DATASET 9 : ÉNERGIE

https://drive.google.com/file/d/1t5ud33_6FFleGFRCOcUKj kf-c2W2MVkB/view?usp=sharing

Description

Cet ensemble de données contient des informations sur la production et la consommation d'énergie, incluant les mesures de capteurs, les coûts et la demande.

Caractéristiques

Multivarié

Domaine

Énergie / Data Science

Tâches

Prévision, Anomalies

Instances

5000

Caractéristiques

20

Variable	Type	Description
----------	------	-------------

plant_id	ID	Centrale
energy_production	Numérique	Production
consumption	Numérique	Consommation
demand	Numérique	Demande
price	Numérique	Prix
temperature	Numérique	Température
pressure	Numérique	Pression
voltage	Numérique	Tension
current	Numérique	Courant
outage_flag	Mixte	Panne
maintenance_date	Date	Maintenance
cost	Numérique	Coût
region	Catégorique	Région

DATASET 10 : MINES

<https://drive.google.com/file/d/1H6L14i9zW3Qvk7P5JFqGi1esgp9iHgn5/view?usp=sharing>

Description

Cet ensemble de données contient des informations relatives aux opérations minières, incluant la production, les coûts, les équipements et les conditions d'exploitation.

Caractéristiques

Multivarié

Domaine

Mines / Industrie

Tâches

Optimisation, Anomalies

Instances

4000

Caractéristiques

20

Variable	Type	Description
mine_id	ID	Mine
mineral	Catégorique	Ressource
production	Numérique	Production
cost	Numérique	Coût
revenue	Numérique	Revenu
profit	Numérique	Profit
depth	Numérique	Profondeur
temperature	Numérique	Température
equipment	Catégorique	Machine
failure_flag	Mixte	Panne
maintenance	Date	Maintenance
workers	Numérique	Effectif
accidents	Numérique	Accidents
safety_score	Numérique	Sécurité
region	Catégorique	Région