

Mamadou Niang**Exercice 1 :**

On cherche à expliquer la consommation des ménages (C) par le revenu (R) :

Travail à faire avec la base « base-1 » : grâce à **R studio**

1. Tracer le nuage de points et commenter.

#Charger la base de données

```
base1=read.table(file.choose(), header = TRUE, sep=";")
```

```
base1
```

```
attach(base1)
```


```
scatterplot (Revenu,Consommation,col="blue",
```

```
  xlab ="Revenu",
```

```
  ylab ="Consommation des menage",
```

```
  main ="Relation entre le revenu et la consommation des ménages")
```

```
abline(lm(Consommation ~ Revenu, data = base1), col = "red")
```



Commentaire :

Le nuage de point montre une relation croissante. L'axe des X représente le Revenu et l'axe Y représente la consommation des ménages.

Le nuage de point montre que la consommation des ménages augmente en même temps que le Revenu.

Les ménages à faible revenu ont une consommation inférieure à 10000 et celle à forte revenu ont tendance à dépasser une consommation de 14000.

2. Peut-on utiliser un modèle de régressions pour expliquer la relation entre la consommation et le revenu ? Justifier

Oui, on peut utiliser un modèle de régression pour expliquer la relation entre la consommation et le revenu.

$$C_t = B_0 + B_1 R_t + \epsilon_t, t=1, \dots, 25$$

Car dans ce modèle, C_t représente la consommation des ménages à un moment donné t , R_t représente le revenu des ménages ce même moment t , B_0 et B_1 sont les paramètres à estimer, et ϵ_t est le terme d'erreur.

Justification :

On peut établir :

Relation linéaire, Estimation des paramètres, Evaluation de l'ajustement du modèle, Prédiction et analyses.

3. Estimer les paramètres du modèle.

```
model = lm(Consommation~Revenu, data=base1)
```

```
model
```

```
summary(model)
```

```

> model = lm(Consommation~Revenu, data=base1)
> model

Call:
lm(formula = Consommation ~ Revenu, data = base1)

Coefficients:
(Intercept)      Revenu
  4393.0886      0.4662

> summary(model)

Call:
lm(formula = Consommation ~ Revenu, data = base1)

Residuals:
    Min       1Q   Median       3Q      Max
-4283.8  -496.4    27.4   790.3  3013.0

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  4.393e+03  1.190e+03   3.691  0.00128 **
Revenu       4.662e-01  8.219e-02   5.672  1.05e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1616 on 22 degrees of freedom
Multiple R-squared:  0.5939,    Adjusted R-squared:  0.5754
F-statistic: 32.17 on 1 and 22 DF,  p-value: 1.053e-05

```

On remarque le **Revenu** à un impact significatif sur la **Consommation** car la p-value est strictement inférieur au seuil de 5% (1,05e-5). Le **Revenu** permet d'expliquer 59,39% du variation total de la **Consommation** des ménages.

Le reste (40,61%) est expliquer par la partie résiduel (l'erreur).

Corrélation linéaire forte entre le Revenu et la Consommation des ménages.

4. En déduire les valeurs estimées de Ct.


$$C_t = 4393 + 0.4662R_t$$

- Pour $t=2007$, $C_t=9987$
- Pour $t=2021$, $C_t=14183$

5. Étudier la présence de valeurs aberrantes.

`plot(model, which = 1)`

L'utilisation de la fonction `plot` nous permet de voir les valeurs aberrantes (13,14)



6. Étudier l'adéquation du modèle.

On a un R carrée qui équivaut à $0.593896 \sim 0.6$ plus proche de 1 que de 0 donc on peut dire qu'on a une bonne adéquation du modèle.

```
> summary(model)$r.squared
[1] 0.593896
```

Le test de Fisher montre $1.053e-05 < \text{seuil} = 0.05$ on rejette l'hypothèse nulle H_0 car la variable consommation est significative pour expliquer la variance du revenu.

```
> anova(model)
Analysis of Variance Table

Response: Consommation
      Df Sum Sq Mean Sq F value    Pr(>F)
Revenu  1 84050772 84050772   32.17 1.053e-05 ***
Residuals 22 57479911 2612723
---
signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

7. Vérifier par un calcul simple la propriété selon laquelle la moyenne des résidus est nulle.

```
model.Bis = lm(Consommation~Revenu, data=base1[-13:-14,]) #suppression  
des valeurs aberrantes
```

```
resid(model.Bis)
```

```
mean(resid(model.Bis))
```

```
> resid(model.Bis)
      1      2      3      4      5      6      7
-765.0615 -778.6961 -517.1591 -114.1607 -293.0307 -313.2276 1276.9448
      8      9     10     11     12     15     16
2758.8218 1990.6988  704.4528 -313.6702 -1831.7932 -795.5472 -472.7317
     17     18     19     20     21     22     23
 168.2068 -100.3076 -1540.7282 1463.5143 -313.6702 -386.1622 -404.2852
     24
  577.5918
> mean(resid(model.Bis))
[1] 3.035451e-14
```

Suite à la suppression des valeurs aberrantes on remarque que la moyenne des résidus est proche de 0 avec une valeur de 3.035451e-14.

8. Calculer l'estimateur de la variance de l'erreur.

```
variance_erreur <- sum(residus^2) / (length(residus) - length(coef(model.Bis)) - 1)
```

```
variance_erreur
```

```
> variance_erreur
[1] 1313992
```

9. Tester la significativité de la pente.

```
> ##*9. Tester la significativité de la pente**
> coefficient_model.Bis<-coef(model.Bis)
> coefficient_model.Bis
(Intercept)      Revenu
4023.702100    0.518123
> pente <- coefficient_model.Bis["Revenu"]
> pente
      Revenu
0.518123
> ecart_type_pente <- summary(model.Bis)$coefficients["Revenu", "Std. Error"]
> ecart_type_pente
[1] 0.05771558
> statistique_test <- pente / ecart_type_pente
> statistique_test
      Revenu
8.977177
> p_value <- 2 * pt(-abs(statistique_test), df = length(resid(model.Bis)) - 2)
> p_value
      Revenu
1.879835e-08
```

Le coefficient est positif pente=0.518123, cela signifie qu'une augmentation de la consommation des ménages est associé à une augmentation du Revenu.

La valeur $p_value=1.879835e-08$ est inférieure à 0.05 donc rejette l'hypothèse H_0 et on conclut que la pente est significativement différente de 0.

10. Construire l'intervalle de confiance au niveau de confiance de 95% pour le paramètre β .

Calculer l'intervalle de confiance

```
borne_inf <- pente - quantile * ecart_type_pente
```

```
borne_sup <- pente + quantile * ecart_type_pente
```

```
> # Afficher l'intervalle de confiance
> print(c(borne_inf, borne_sup))
      Revenu      Revenu
0.3977304 0.6385156
```

L'intervalle de confiance est compris entre [0.3977304, 0.6385156].

Les bornes sont calculées en ajoutant et en soustrayant le produit du quantile de la distribution normale standard et de l'écart-type de chaque coefficient estimer. (Voir fichier R)

11. Calculer le coefficient de détermination et effectuer le test de Fisher permettant de déterminer si la régression est significative dans son ensemble.

```
> summary(model.Bis)

Call:
lm(formula = Consommation ~ Revenu, data = base1[-13:-14, ])

Residuals:
    Min       1Q   Median       3Q      Max
-1831.8  -506.1  -313.4   475.2  2758.8

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  4.024e+03  8.258e+02   4.872 9.22e-05 ***
Revenu       5.181e-01  5.772e-02   8.977 1.88e-08 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1117 on 20 degrees of freedom
Multiple R-squared:  0.8012,    Adjusted R-squared:  0.7912
F-statistic: 80.59 on 1 and 20 DF,  p-value: 1.88e-08
```

On a un R^2 égal à 0.8012 proche de 1 donc on a un ajustement parfait des données et on a un test F-statistique=80.59 ce qui montre que la consommation a un effet significatif sur le revenu.

12. Écrire et vérifier l'équation d'analyse de la variance. Interpréter.

```
> ##12. Écrire et vérifier l'équation d'analyse de la variance. Interpréter.  **
> # Calculer la somme des carrés totaux (SCT)
> data=base1[-13:-14,]
> SCT <- sum((data$Consommation - mean(data$Consommation))^2)
>
> # calculer la somme des carrés de la régression (SSR)
> SSR <- sum((predict(model.Bis) - mean(base1$Consommation))^2)
>
> # Calculer la somme des carrés des résidus (SCR)
> SCR <- sum(resid(model.Bis)^2)
>
> # vérifier l'équation ANOVA
> SST_verifie <- SSR + SCR
>
> # Afficher les résultats
> print(SCT)
[1] 125565337
> print(SSR)
[1] 101903311
> print(SCR)
[1] 24965841
> print(SST_verifie)
[1] 126869152
```

Interprétation :

On a un grand SSR (Somme des Carrés de la Régression) =101903311 par rapport à notre SCR (Somme des Carrés de la Résidus) =24965841 indiquant que le modèle explique une grande partie de la variation de la consommation des ménages donc le modèle est significatif.

13. Après un travail minutieux, un étudiant de L1 FASE trouve le coefficient de corrélation linéaire entre Ct et Rt suivant $r_{XY} = 0.99789619$. Sans le moindre calcul, tester la significativité de ce coefficient. Argumenter.

```
> cor.test(Revenu,Consommation)

Pearson's product-moment correlation

data: Revenu and Consommation
t = 5.6718, df = 22, p-value = 1.053e-05
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.5328926 0.8956088
sample estimates:
      cor
0.7706294
```

Argumentation


- Sans effectuer de calculs, nous pouvons raisonnablement affirmer que le coefficient de corrélation $r_{XY} = 0.99789619$ est très proche de 1. En général un coefficient de corrélation proche de 1 suggère une forte relation linéaire entre la consommation des ménages par le revenu.
- La significativité du test montre une corrélation de 0.7706294 proche de 1 et une $p_value < \text{seuil} = 0.05$ donc l'étudiant à un coefficient de corrélation très élevé par rapport à la corrélation du modèle étudié cela peut s'expliquer par un non ajustement du modèle.

14. En 2024 et 2025, on prévoit respectivement 16800 et 17000 euros pour la valeur du revenu. Déterminer les valeurs prévues de la consommation pour ces deux années, ainsi que l'intervalle de prévision au niveau de confiance de 95%.

```
> ##14. En 2024 et 2025, on prévoit respectivement 16800 et 17000
euros pour*
> ## la valeur du revenu. Déterminer les valeurs prévues de la
consommation*
> ##pour ces deux années, ainsi que l'intervalle de prévisi
on au niveau de*
> ## confiance de 95%. **#
> nouvelles_donnes<-data.frame(Revenu = c(16800, 17000))
> nouvelles_donnes
  Revenu
1 16800
2 17000
> valeurs_prevues <- predict(model.Bis, nouvelles_donnes)
> valeurs_prevues
      1      2
12728.17 12831.79
> intervalle_prediction <- predict(modele, nouvelles_donnes, interval = "prediction", l
evel = 0.95)
Erreur : objet 'modele' introuvable
> intervalle_prediction <- predict(model.Bis, nouvelles_donnes, interval = "predictio
n", level = 0.95)
> intervalle_prediction
      fit      lwr      upr
1 12728.17 10316.16 15140.18
2 12831.79 10415.94 15247.65
```


Exercice 2 :

1) Existe-t-il une corrélation entre les variables explicatives ? Si oui, précisez quelles variables et analyser les résultats.




On remarque que l'ACP nous montre que (T15 : température observée à 15 heures ; T18 : température observée à 18 heures ; T9 : température observée à 9 heures) sont corrélés positivement entre eux sur les 2 axes tandis que les nébulosités observées sont corrélées négativement sur la Dim1 pour (N9 : nébulosité observée à 9 heures ; N12 : nébulosité observée à 12 heures ; N15 : nébulosité observée à 15 heures) et les nébulosités (N6 : nébulosité observée à 6 heures ; N18 : nébulosité observée à 18 heures) sont corrélés positivement sur la Dim2.

Analyse des résultats :

- Ces résultats montrent que la **VVENT : vitesse du vent** et la **concentration d'ozone** sont beaucoup plus important quand les **températures** commencent à **grimper** entre 9H et 18H et rare la matinée 6h.
- La nébulosité est plus important quand la **VVENT : vitesse du vent** et la **concentration d'ozone** sont faible la journée.

2) Ajuster un modèle de régression linéaire multiple et étudier l'adéquation du modèle. Analyser les résultats (Effectuez toutes les étapes de l'analyse).

- Etude de la linéarité entre les variables :
`ggpairs(base2)`



ce graphique conforte notre analyse précédente sur la corrélation de la température et la nébulosité par rapport à la **VVENT** : vitesse du vent et la **concentration d'ozone**.

- Ajustement du modèle :
`model_1=lm(ozone ~. , data = base2)`

```
> model_1=lm(ozone ~. , data = base2) # prends toutes les covariables
> model_1

Call:
lm(formula = ozone ~ ., data = base2)

Coefficients:
(Intercept)          T6          T9          T12          T15          T18
    34.2980     -3.1770     5.2262    -0.9113    -2.7160     3.7534
          N6          N9          N12          N15          N18          VVENT
    -3.7934     0.9452     0.2637    -4.7141     3.2976     1.7717
```

Rcarrer=0.5942

```
> summary(model_1)

Call:
lm(formula = ozone ~ ., data = base2)

Residuals:
    Min       1Q   Median       3Q      Max
-48.678 -12.144  -0.357   11.737   61.544

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   34.2980     21.7310   1.578  0.11849
T6             -3.1770      1.8659  -1.703  0.09256 .
T9              5.2262      3.2558   1.605  0.11244
T12            -0.9113      3.6028  -0.253  0.80097
T15            -2.7160      3.2169  -0.844  0.40105
T18             3.7534      2.0515   1.830  0.07108 .
N6             -3.7934      1.3735  -2.762  0.00714 **
N9              0.9452      2.0866   0.453  0.65181
N12             0.2637      2.3666   0.111  0.91158
N15            -4.7141      2.6952  -1.749  0.08417 .
N18             3.2976      2.0140   1.637  0.10554
VVENT          1.7717      1.0357   1.711  0.09108 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 23.92 on 79 degrees of freedom
Multiple R-squared:  0.5942,    Adjusted R-squared:  0.5376
F-statistic: 10.51 on 11 and 79 DF,  p-value: 1.39e-11
```


- **Etudes des valeurs atypiques :**
 1. Les residus stendentisé pour chaque observation :

```
> rstud
```

1	2	3	4	5	6
-0.501338481	-0.536971522	-0.538155007	-0.720394495	-1.668075544	-1.444087385
7	8	9	10	11	12
-1.953757584	-0.564013910	-1.304063949	-1.042943275	-1.482904613	-1.452700819
13	14	15	16	17	18
-0.997546233	-0.965906304	-2.032235850	-0.714172094	-0.177640895	-1.474242333
19	20	21	22	23	24
-1.658216594	0.265727233	-1.320256232	-1.305561150	-1.167444376	-2.188473701
25	26	27	28	29	30
0.386509352	-0.325690540	0.007646436	0.165042857	-0.304041432	0.421775997
31	32	33	34	35	36
-0.348194157	0.260414910	0.134651110	-0.216410416	0.020768870	0.268142939
37	38	39	40	41	42
-0.923516815	-0.006811915	-0.016475580	-0.277745437	-0.007523144	0.492296046
43	44	45	46	47	48
-0.054002675	1.681195621	-0.180311674	0.491365063	0.248619336	-0.440648552
49	50	51	52	53	54
-0.239540358	-0.257067946	1.970738235	0.225691455	-0.153842688	0.336541343
55	56	57	58	59	60
-0.191645124	1.978759296	0.890873921	1.466229725	1.641917449	-0.066260448
61	62	63	64	65	66
0.878233567	0.969487905	1.453521609	1.326810153	2.909853316	-0.146262054
67	68	69	70	71	72
0.651552816	-1.313955202	0.794646114	0.287536224	0.204883639	1.044808024
73	74	75	76	77	78
0.301691927	-1.065219789	-0.153852136	1.512394844	-0.517737811	-0.101958848
79	80	81	82	83	84
-0.168886222	0.522015125	1.153095251	1.222417601	0.019835069	1.988249491
85	86	87	88	89	90
0.577771462	0.252300305	1.915256637	0.600951008	-0.792746678	1.020688748
91					
0.457366392					

2.influence des index :






Ces graphes montre les differentes valeurs qui s'éloigne de l'axe horizontale etant potentiellement influentes (65, 15, 24) ou aberrantes (13, 35, 2).

- comparaison des coefficients :
modelbis meilleur que model_1 car son AIC est faible

```
> AIC(model_1)
[1] 849.1875
> AIC(modelbis)
[1] 823.6472
```

- Adéquation du modèle :



On observe une bonne linéarité des variables observés et 65, 15, 84 sont les plus influentes.

```
> check_normality(modelbis)
OK: residuals appear as normally distributed (p = 0.460).

> check_heteroscedasticity(modelbis)
OK: Error variance appears to be homoscedastic (p = 0.503).

> summary(residus)
      Min.   1st Qu.   Median     Mean   3rd Qu.    Max.
-48.0984 -12.2963  -0.3125   0.0000  12.1341  61.0097
```

- **Colinearite des variables explicatives :**

Les facteurs d'inflation de la variances

```
> vif1 = vif(modelbis)
> vif1
      T6      T9      T12      T15      T18      N6      N9      N12
4.988691 22.270340 45.509795 40.655716 15.979171  2.857037  5.297457  7.523135
      N15      N18      VVENT
11.078088  4.662943  1.633419
> check_collinearity(modelbis)
# Check for Multicollinearity

Low Correlation

Term  VIF      VIF 95% CI Increased SE Tolerance Tolerance 95% CI
T6  4.99 [ 3.69,  6.92]      2.23      0.20 [0.14,  0.27]
N6  2.86 [ 2.19,  3.90]      1.69      0.35 [0.26,  0.46]
N18 4.66 [ 3.46,  6.45]      2.16      0.21 [0.15,  0.29]
VVENT 1.63 [ 1.34,  2.19]      1.28      0.61 [0.46,  0.75]

Moderate Correlation

Term  VIF      VIF 95% CI Increased SE Tolerance Tolerance 95% CI
N9  5.30 [ 3.91,  7.35]      2.30      0.19 [0.14,  0.26]
N12 7.52 [ 5.47, 10.51]      2.74      0.13 [0.10,  0.18]

High Correlation

Term  VIF      VIF 95% CI Increased SE Tolerance Tolerance 95% CI
T9 22.27 [15.86, 31.44]      4.72      0.04 [0.03,  0.06]
T12 45.51 [32.23, 64.43]      6.75      0.02 [0.02,  0.03]
T15 40.66 [28.82, 57.54]      6.38      0.02 [0.02,  0.03]
T18 15.98 [11.43, 22.51]      4.00      0.06 [0.04,  0.09]
N15 11.08 [ 7.98, 15.56]      3.33      0.09 [0.06,  0.13]
```